



Integración de datos ICFES

Vinculación longitudinal Saber 11 – Saber Pro (2014–2025)

Informe técnico — Proyecto 1

Estudiantes

Michelle Báez

Silvio Herrera

Jari Villar

Estadística Industrial

30/08/2026

Santa Marta

Tabla de contenido

Tabla de contenido.....	2
1. Resumen	3
Cifras clave.....	3
2. Fuentes de datos.....	3
2.1 Inventario de archivos.....	4
2.2 Periodos efectivamente disponibles vs. periodos con datos reales	4
3. Estrategia de integración.....	4
3.1 Llave de vinculación.....	4
3.2 Tipo de unión y criterio de inclusión	5
3.3 Tratamiento de duplicados y presentaciones	5
3.4 Reglas de consistencia temporal y rezago.....	6
3.5 Diagrama de flujo de datos	6
4. Limpieza y estandarización	7
4.1 Problemas de identificadores	7
4.2 Problemas de esquema de variables cambiante entre años	7
4.3 Problemas de formato y tipo de dato	7
4.4 Problemas de disponibilidad de variables entre periodos	7
4.5 Problemas de escala y rango de puntaje	8
4.6 Los casos más difíciles (priorizados).....	8
5. Validación y calidad	8
5.1 Calidad general de la base	8
5.2 Matriz de cobertura de cohortes y patrón de rezago	9
5.3 Interpretación de la tasa de vinculación por régimen.....	9
5.4 Sesgo introducido por la vinculación parcial.....	9
5.5 Prueba formal de sesgo de selección	9
6. Reproducibilidad y automatización	11
6.1 Qué cambiar para incorporar un año nuevo	11
6.2 Entorno	11
7. Limitaciones	11
8. Uso de inteligencia artificial	12
En que apporto:.....	12
Dónde falló o requirió corrección	12
Cómo se verificó cada output	13
Anexos.....	13

1. Resumen

Se construyó una base de datos longitudinal a nivel individual de los estudiantes registrados, con el fin de vincular los resultados de las pruebas Saber 11, correspondientes al intervalo comprendido entre los años 2014 y 2025, con los resultados del módulo de competencias genéricas de la prueba Saber Pro de dichos estudiantes. Para realizar esta vinculación, se utilizó una tabla puente oficial de cruces entre ambas pruebas, que permitió identificar y relacionar los resultados correspondientes a un mismo individuo, posibilitando la comparación y evaluación de su desempeño entre las dos pruebas.

La base de datos comprende un total de 11 años de datos registrados dentro del intervalo establecido para ambas pruebas. Su construcción se realizó mediante el uso de scripts de programación, a partir de 7.694.905 registros originales de Saber 11 y de una tabla puente que contenía 2.824.722 pares candidatos estudiante–estudiante, utilizados en el proceso de validación y emparejamiento.

Como resultado del proceso de depuración, vinculación y consolidación, se obtuvo una base de datos final compuesta por 758.327 registros y 41 variables. Estos registros corresponden a las observaciones resultantes del proceso de emparejamiento entre ambas pruebas, consolidando en una misma base la información disponible de los estudiantes que pudieron ser vinculados mediante la tabla puente oficial.

Cifras clave

Indicador	Valor
Registros en la base final	758.327
Variables en la base final	41
Cohortes de Saber 11 con al menos un emparejamiento	20 de 24 (2014-1 a 2023-2)
Tasa de vinculación global	9,85 %
Tasa de vinculación — régimen sin censura (2014-1 a 2023-1)	13,18 %
Tasa de vinculación — cohortes con mayor tiempo transcurrido (2014-1 a 2020-2)	17,40 %
Rezago mediano entre pruebas	60 meses (5 años)

La tasa de vinculación global (9,85 %) subestima la vinculación real de las cohortes que ya tuvieron tiempo suficiente de completar estudios superiores: al excluir las cohortes afectadas por censura por la derecha (2023-2 en adelante), la tasa sube a 13,18 %, y si se restringe a las cohortes más antiguas (2014-1 a 2020-2, con al menos 4 años de margen) sube a 17,40 %. Esta diferencia es estructural — producto del tiempo de rezago entre pruebas — y se documenta en detalle en la sección 5.

2. Fuentes de datos

El proyecto cubre 24 periodos de Saber 11 (2014-1 a 2025-2) y 11 años de Saber Pro — módulo de competencias genéricas (2014 a 2024), más una tabla puente única que vincula ambas pruebas al mismo estudiante.

2.1 Inventario de archivos

Fuente	Cobertura	Convención de nombre de archivo	N.º de archivos esperados
Saber 11	2014-1 a 2025-2 (24 periodos)	Examen_Saber_11_{periodo}	24
Saber Pro (genéricas)	2014 a 2024 (11 años)	Examen_Saber_Pro_Genericas_{periodo}	11
Tabla de cruces	Histórica, un solo archivo	"Cruce Examen Saber 11 - Examen Saber Pro" (nombre libre, único archivo en la carpeta)	1

Formato de todos los archivos de entrada: separador ';', con lectura defensiva de encoding (se intenta UTF-8, luego Latin1, luego WINDOWS-1252) y un conjunto propio de cadenas interpretadas como valor faltante ('', 'NA', 'N/A', '-', '*', 'NULL', 'sin dato'). La convención de nombres fue confirmada por el equipo contra archivos reales el 24 de agosto de 2026.

2.2 Periodos efectivamente disponibles vs. periodos con datos reales

Los archivos de ambas pruebas se descargaron el 10 de agosto de 2026 desde el portal oficial del ICFES (https://icfesgovco.sharepoint.com/sites/DataIcfes2.0/SitePages/Saber11_Bases-y-documentaci%C3%B3n%20t%C3%A9cnica.aspx), previa autorización de acceso mediante un formulario de solicitud. Cada archivo se descargó individualmente, para evitar que un paquete comprimido único quedara ilegible ante un error de descarga.

De los 24 periodos configurados para Saber 11, la base final contiene registros emparejados únicamente para 20 (2014-1 a 2023-2); los periodos 2024-1 en adelante aún no presentan emparejamientos, dado que sus egresados no han tenido tiempo suficiente para presentar Saber Pro dentro de la ventana de datos disponible (ver sección 5).

El diccionario de variables (docs/diccionario_variables.xlsx) sigue en construcción, tal como lo advierte explícitamente el README del repositorio (“aún en construcción — ampliar a medida que se revisen más variables”). Ya cubre la presencia/ausencia de cada variable en los 24 periodos de Saber 11 y los 11 años de Saber Pro, y documenta tipo, descripción oficial y categorías para la mayoría de las variables, pero quedan pendientes al menos: (i) la fila de “periodo”, sin descripción ni categorías; (ii) la distinción entre las versiones _s11 y _spro de variables que existen en ambas pruebas con nombre compartido en el diccionario pero separado en la base final (estu_genero, estu_etnia, punt_global); y (iii) una revisión de las descripciones oficiales de punt_matematicas y punt_c_naturales, que actualmente mencionan competencias de otra área (física y biología, respectivamente) en vez de matemáticas y ciencias naturales.

3. Estrategia de integración

3.1 Llave de vinculación

En las pruebas saber 11 y saber pro no existe un identificador nativo común, cada prueba le asigna un código propio con un esquema distinto (en el caso de las saber pro inicia con “SB” seguido de números y en saber pro “EK” seguido de número). Por esta diferencia es necesario relacionar las dos pruebas a través de un “puente”, entregado por la fuente de datos. Este documento es el “Cruce Examen Saber 11 – Examen Saber Pro”, este archivo cuenta con 4 columnas, dos para mostrar los respectivos identificadores y dos que muestran el periodo de realización de cada prueba. Esta llave se trata como texto (no como número) en toda la base, porque el identificador puede contener letras. Tratarla como número fue, de hecho, el primer error detectado en el proyecto: convertía el identificador en NA y dejaba el cruce en 0 registros emparejados.

3.2 Tipo de unión y criterio de inclusión

Se aplicó una unión interna (inner join) en dos pasos sucesivos: primero la tabla puente se une con Saber 11 por la variable `estu_consecutivo_sb11`, y el resultado se une con Saber Pro por su variable `estu_consecutivo_sbpro`. Solo sobreviven en la base final los estudiantes que existen simultáneamente en las tres fuentes (tabla puente o tabla de cruces, Saber 11 y Saber Pro).

Un registro entra a la base final si cumple, en este orden:

- Existe como par en la tabla puente (`estu_consecutivo_sb11 + estu_consecutivo_sbpro`).
- Su Saber 11 y su Saber Pro existen efectivamente en los microdatos consolidados (no todo lo que aparece en la tabla puente tiene un registro de datos correspondiente).
- El periodo de Saber Pro es estrictamente posterior al periodo de Saber 11.

3.3 Tratamiento de duplicados y presentaciones

Un mismo estudiante puede aparecer más de una vez en cualquiera de las dos pruebas (por ejemplo, si repitió el examen). Antes de cruzar, cada prueba se reduce a un registro por estudiante, aplicando una regla distinta para cada una:

- Saber 11 → PRIMERA presentación: representa el punto de partida real del estudiante al salir del colegio, sin el efecto de haber repetido el examen para subir el puntaje.
- Saber Pro → ÚLTIMA presentación: refleja el resultado más consolidado del estudiante en su trayectoria de educación superior (por ejemplo, tras un reingreso), que es lo que interesa medir en un estudio sobre el efecto de la educación superior.

La garantía de unicidad se verifica automáticamente después del cruce por lo que en los duplicados residuales no existe ningún valor, confirmando que ningún estudiante quedó repetido en la base final.


3.4 Reglas de consistencia temporal y rezago

Cada periodo se convierte a un valor numérico comparable (año.semestre para Saber 11, año para Saber Pro) mediante la función periodo_a_valor(). Con eso estipulado se aplican dos reglas:

- Orden temporal obligatorio: se excluye cualquier registro donde Saber Pro no sea estrictamente posterior a Saber 11 (orden invertido o ambas pruebas en el mismo periodo). No se corrige a mano -se excluye y se cuenta-, porque un orden inválido es evidencia de un error de emparejamiento, no algo que el equipo pueda arreglar con criterio.
- Rezago plausible: el tiempo transcurrido entre las dos pruebas se calcula en meses y años (`periodo_a_meses()`), y se marca como "implausible" fuera del rango 12-144 meses. El mínimo (12 meses) refleja que ni el programa de educación superior más corto se completa en menos de un año; el máximo (144 meses, 12 años) coincide con el propio horizonte de la ventana de datos del proyecto (2014-2025).

3.5 Diagrama de flujo de datos

Ahora se presenta un diagrama de flujo de datos dentro del código antes de llegar a la base final.



4. Limpieza y estandarización

4.1 Problemas de identificadores

estu_consecutivo se leyó inicialmente como variable numérica (junto con el resto de puntajes). Como el identificador real contiene letras ("SB11...", "EK..."), la conversión lo volvía NA de forma sistemática. Se detectó porque el cruce Saber 11 - Saber Pro daba 0 registros en la primera corrida real. Se corrigió excluyendo estu_consecutivo de la lista de variables numéricas y tratándolo como texto en toda la base.

4.2 Problemas de esquema de variables cambiante entre años

- El nombre de las variables de puntaje por competencia cambió con los años: el esquema moderno (punt_c_naturales, punt_sociales_ciudadanas, punt_lectura_critica, punt_matematicas, punt_ingles) es el estándar en todos los periodos de Saber 11, confirmado contra el diccionario de variables terminado.
- El periodo 2014-1 llega con esas mismas cinco competencias bajo el prefijo recaf_ (recalificadas) en vez del nombre estándar. Se resolvió renombrando esas columnas hacia el nombre estándar antes de la selección de variables, para que el valor caiga en la misma columna que usan los otros 23 periodos. Esta solución derivó en otro problema, en el archivo de 2014-1 existían DOS columnas para inglés al mismo tiempo (punt_ingles original y recaf_punt_ingles recalificada). Un renombrado simple dejaba dos columnas con el mismo nombre final y el valor recalificado se perdía en silencio. Se corrigió con una regla explícita de prioridad: cuando la columna destino ya existe, se sobrescribe con el valor recalificado en vez de conservar el original.

4.3 Problemas de formato y tipo de dato

fami_estratovivienda llega como texto ("Estrato 3", "Sin Estrato"), no como número puro. Forzar una conversión numérica directa (as.numeric) volvía NA a la inmensa mayoría de los registros - cientos de miles por periodo en la corrida real. Se corrigió conservando el texto original y derivando una columna numérica aparte (fami_estrato_num) que extrae el dígito 1-6 cuando existe.

4.4 Problemas de disponibilidad de variables entre periodos

No todas las variables existen en todos los periodos -el diccionario documenta explícitamente, variable por variable, en qué periodos está disponible cada una. La solución de fondo es la selección defensiva de columnas: el código nunca asume que una columna existe, siempre la busca contra lo que realmente trae el archivo y completa con NA lo que falte, sin detener la lectura.

4.5 Problemas de escala y rango de puntaje

- Un rango teórico único (0-100) aplicado a los 12 años de la serie generaba falsos positivos de "fuera de rango", porque las escalas de calificación del ICFES cambiaron con el tiempo. Se corrigió segmentando los rangos esperados por variable Y por ventana de periodo.
- El rango de `punt_global_s11` estaba documentado como 0-100 en el diccionario -una nota que en realidad se refería a los puntajes por competencia individual, no al puntaje global. Se corrigió a 0-500 tras confirmarlo con el equipo.

4.6 Los casos más difíciles (priorizados)

- 1. Cruce en 0 registros (identificador tratado como número): el más grave, porque invalidaba todo el pipeline sin ningún mensaje de error -el código corría de principio a fin "exitosamente" y entregaba una base vacía.
- 2. Rezago con valores absurdos (choque de nombres en `data.table`): el más sutil de detectar, porque tampoco producía ningún error; el código corría bien pero calculaba un rezago de miles de meses en vez de decenas, por una ambigüedad entre el parámetro de una función y una columna del mismo nombre ya presente en los datos.
- 3. Pérdida silenciosa del valor recalificado (choque de columnas en 2014-1): el más difícil de anticipar, porque no generaba error ni un valor obviamente incorrecto -solo un dato correcto reemplazado por otro dato también válido, pero desactualizado. Se detectó por inspección manual, comparando el archivo original contra la base procesada.

5. Validación y calidad

El reporte de validación (fase 5 del pipeline, regenerado automáticamente en cada ejecución de `run_all.R`) se resume en las siguientes métricas:

5.1 Calidad general de la base

Métrica	Valor
Duplicados residuales en la base final	0
Valores fuera de rango (todas las variables)	73 de 758.327 en <code>punt_matematicas</code> (0,0096 %); resto en 0
Registros con rezago implausible	1.299 (0,17 %) — marcados, no eliminados
Pares excluidos por orden temporal inválido	4.189 de 2.824.722 en la tabla puente (0,15 %)

5.2 Matriz de cobertura de cohortes y patrón de rezago

La distribución del rezago entre Saber 11 y Saber Pro tiene mediana de 60 meses (5 años), con p25 en 54 meses y p75 en 78 meses (rango 6–120 meses). La matriz de cobertura de cohortes muestra, para cada cohorte de Saber 11, un pico de emparejamientos consistentemente ubicado 4 a 5 años después: por ejemplo, la cohorte 2014-2 (574.259 estudiantes) alcanza su pico de 49.185 emparejamientos en 2019, y la cohorte 2015-2 (574.158 estudiantes) alcanza su pico de 48.196 en 2020. Este patrón, observado empíricamente y no supuesto de antemano, confirma que el rezago entre pruebas es la explicación dominante de por qué las cohortes recientes muestran baja vinculación.

5.3 Interpretación de la tasa de vinculación por régimen

No se reporta una tasa de vinculación única: el pipeline clasifica cada periodo de Saber 11 en un régimen de cobertura (normal o censura por la derecha probable) según cuánto tiempo ha transcurrido desde ese periodo hasta el último año disponible de Saber Pro (2024).

Régimen	Periodos	Candidatos Saber 11	Emparejados	Tasa
Régimen normal	2014-1 a 2023-1	5.754.413	758.298	13,18 %
Censura por la derecha probable	2023-2 a 2025-2	1.940.492	29	0,001 %

Se identifica una inconsistencia menor en el umbral de corte configurado en el pipeline (config.yml): el periodo 2023-1 queda clasificado como "régimen normal" pero su tasa observada (0,01 %; 5 de 77.555) es prácticamente idéntica a la de los periodos ya clasificados como censurados. Se reporta esta inconsistencia de forma transparente en vez de ocultarla; el equipo evaluará si mover el umbral un periodo antes (ver docs/registro_decisiones.md).


5.4 Sesgo introducido por la vinculación parcial

Incluso en el régimen sin censura, la tasa de vinculación (13,18–17,40 % según la ventana considerada) implica que la gran mayoría de quienes presentan Saber 11 no llegan a presentar Saber Pro dentro de la ventana observada. Esto no es evidencia de un error de cruce, sino un reflejo esperado de las tasas de acceso y permanencia en educación superior en Colombia. Sin embargo, tiene una consecuencia metodológica importante: la submuestra emparejada no es representativa de la población general de egresados de Saber 11, sino de un subgrupo autoseleccionado que ingresó y permaneció en educación superior hasta presentar Saber Pro. Cualquier análisis posterior sobre esta base debe advertir este sesgo de selección explícitamente.

5.5 Prueba formal de sesgo de selección

A partir de la v9 del proyecto, esta afirmación deja de ser solo cualitativa: el script analisis/02_sesgo_seleccion.R (independiente de run_all.R, se corre después) prueba formalmente si la vinculación a Saber Pro está asociada al estrato (fami_estrato_num), género (estu_genero) o tipo de colegio (cole_naturaleza) del estudiante, mediante una prueba chi-cuadrado de independencia por variable y la proporción vinculada por categoría con intervalo de confianza del 95 %. El análisis excluye explícitamente las cohortes bajo censura por la derecha probable

(identificadas en tasa_vinculacion_por_cohorte.csv), para no inflar artificialmente la asociación con cohortes que aún no han tenido tiempo de vincularse.



Se observo en este caso que sobre 2.448.127 estudiantes de saber 11 (excluida censura por la derecha), el 5,0 % (123.459) llegaron a hacer las pruebas saber pro. Confirmado por medio de una prueba chi-cuadrado.

6. Reproducibilidad y automatización

El flujo completo se ejecuta con un único punto de entrada: abrir `proyecto_icfes.Rproj` en RStudio (para que las rutas relativas funcionen) y correr `source("run_all.R")`, o bien `Rscript run_all.R` desde terminal parado en la raíz del proyecto. No hay pasos manuales intermedios ni scripts que deban correrse en un orden distinto — `run_all.R` orquesta las 8 etapas del pipeline (ver diagrama, sección 3.5) en secuencia.

Cada periodo procesado guarda un checkpoint en formato Parquet en `data/interim/`; en ejecuciones posteriores, el pipeline reutiliza automáticamente los checkpoints ya generados y solo procesa periodos nuevos o que hayan cambiado, en vez de reprocesar los 12 años completos cada vez.

6.1 Qué cambiar para incorporar un año nuevo

Según el README del repositorio, el procedimiento es: (1) agregar el nuevo periodo a `config.yml` → sección `periodos`; (2) colocar el archivo fuente correspondiente en `data/raw/Saber11/` o `data/raw/SaberPro/`, respetando el patrón de nombre (`Examen_Saber_11_{periodo}` o `Examen_Saber_Pro_Genericas_{periodo}`); (3) volver a ejecutar `Rscript run_all.R`. No es necesario modificar ningún script dentro de R/ — el diseño explícitamente evita escribir años o periodos directamente en el código.

6.2 Entorno

- R 4.6.1, con los paquetes `data.table`, `arrow`, `yaml`, `readxl`, `stringr`, `stringi`, `purrr`, `glue` y `lubridate`.
- Semilla aleatoria fija, definida en `config.yml` (`semilla_aleatoria`).
- Equipo de referencia usado por el equipo original: 16 GB RAM; el flujo procesa un periodo a la vez y libera memoria (`gc()`) entre ciclos para no requerir cargar los 12 años completos en memoria simultáneamente.

7. Limitaciones

Esta sección documenta explícitamente qué no se logró y qué precauciones debe tomar quien use la base, siguiendo el principio de que reportar una limitación con precisión suma puntos frente a ocultarla.

- Trazabilidad del valor recalificado en 2014-1: desde el 25-ago, el valor `recaf_*` queda fusionado directamente en la columna estándar (`punt_c_naturales`, etc.), por lo que ya no es distinguible a simple vista de un valor no recalificado sin cruzar por `periodo_s11` y `archivo_origen`; quien necesite aislar específicamente los casos recalificados debe hacerlo por esa vía, no por nombre de columna.
- Homologación de categorías y geografía DANE aún no aplicada: las tablas de equivalencia (`config/homologacion_categorias.csv`, `config/homologacion_geografia_dane.csv`) existen como plantillas vacías; mientras no se completen, el renombre de `fami_estratovivienda` en 2019 y la codificación oficial de departamento/municipio no están reflejados en la base final.

- Rezago calculado con el mes de aplicación aproximado (junio para Saber Pro, por no conocerse el mes real), con una imprecisión de hasta ± 6 meses en `rezago_meses` y `rezago_anios` para todos los registros.
- Cobertura parcial en cohortes recientes: los periodos 2023-2 en adelante están bajo censura por la derecha probable (29 emparejamientos o menos); no deben usarse para estimar tasas de vinculación ni conclusiones sobre esas cohortes hasta que existan más años de Saber Pro disponibles.
- Umbral de censura no perfectamente alineado con el comportamiento observado en los datos (ver sección 5.3); se documenta la inconsistencia en vez de ajustarla silenciosamente.
- Sesgo de selección en la submuestra emparejada (ver sección 5.4): no representa a la población general de examinados de Saber 11, solo a quienes continuaron hasta presentar Saber Pro.
- Registros con rezago implausible: 1.299 (0,17 % del total) quedan marcados con `rezago_implausible = TRUE` en vez de eliminarse de la base. Esta decisión traslada la responsabilidad de incluirlos o excluirlos a quien haga el análisis posterior, según si esos casos son ruido o información relevante para su pregunta específica

8. Uso de inteligencia artificial

El equipo usó IA (Claude) como apoyo durante todo el desarrollo del proyecto: desde el diseño inicial de la arquitectura del pipeline hasta la depuración de errores y la redacción de este informe. El detalle completo de las 20 interacciones registradas está en el Anexo A (`docs/bitacora_ia.md`); esta sección resume los patrones más relevantes.

En que aportó:

- Diseño de la arquitectura modular en R (`config.yml` + scripts numerados por fase) a partir de las restricciones reales del entorno (separador `;`, R 4.6.1, 16 GB de RAM).
- Ajuste de la configuración a los nombres reales de archivos y columnas una vez el equipo los confirmó, evitando dejar supuestos genéricos en el código.
- Ampliación del módulo de validación (`07_validacion.R`) para cubrir exactamente el checklist exigido por el profesor (matriz de cobertura, distinción "no preguntado" vs. "no respondido", régimen por cohorte).
- Solución de portabilidad (`proyecto_icfes.Rproj`) para que el proyecto corriera igual en los computadores de los tres integrantes, priorizada sobre alternativas más frágiles (editar rutas a mano, `file.choose()`).

Dónde falló o requirió corrección

- Un primer intento de generar la estructura de carpetas produjo una carpeta corrupta por un bug de expansión de llaves en el comando usado; se detectó por captura de pantalla del equipo y se corrigió regenerando el proyecto.

- La primera corrida real del cruce Saber11–SaberPro devolvió 0 registros: la causa fueron dos bugs concretos (estu_consecutivo tratado como numérico, perdiendo el valor en IDs con letras, y llaves de la tabla de cruces sin normalizar antes de cruzar).
- Un bug de mutación por referencia en data.table (06_cruce.R) alteraba el orden visible de las tablas en el Environment de RStudio, generando una falsa alarma de "faltan periodos" que en realidad era solo un problema de visualización.
- El manejo de las columnas recaf_* del periodo 2014-1 cambió de decisión dos veces durante el proyecto (columnas separadas → fusión directa), y en la fusión apareció un bug donde punt_ingles no se actualizaba y conservaba el valor viejo cuando ambas columnas coincidían en nombre; se corrigió priorizando explícitamente el valor recalificado.

Cómo se verificó cada output

Cada ajuste al código se sometió a una verificación concreta antes de darlo por válido, no a una simple revisión visual:

- Los errores reportados siempre se acompañaron de evidencia directa —capturas de pantalla del mensaje exacto o el log completo de ejecución— de modo que la corrección respondiera a la causa real del problema y no a una descripción aproximada de este.
- Los valores calculados se cotejaron manualmente contra los archivos .csv originales cuando su magnitud generaba dudas; así se confirmó, por ejemplo, que un valor como "106" correspondía al dato real y no a un error de conversión decimal.
- Cada versión del reporte de validación se contrastó punto por punto contra el checklist entregado por el profesor, en vez de darla por completa según el criterio propio del equipo.

Anexos

- Anexo A — Bitácora de uso de IA (docs/bitacora_ia.md)
- Anexo B — Registro de decisiones metodológicas (docs/registro_decisiones.md)
- Anexo C — Diccionario de la base final (data/output/diccionario_base_final.csv)
- Anexo D — Reporte de validación completo (data/output/validacion/)